Valores no texto, segurança no raciocínio: o ajuste fino com conteúdo de valores altera a segurança de LLMs pela deliberação, não pelo conteúdo

Autor(a) 1[1] e Autor(a) 2[1]

1- Universidade Federal de Pelotas - Centro de Desenvolvimento Tecnológico
Pelotas, RS - Brasil

Resumo. Ajustar finamente um LLM com raciocínio em textos benignos pode corroer sua segurança. Investigamos se o *conteúdo de valores* do corpus importa. Treinamos 90 modelos de seis famílias (Qwen3 1,7–32B, Phi-4, Gemma 4, Mistral Nemo, Granite, OLMo 2) com textos de direitos humanos (DUDH), amorais (*As 48 Leis do Poder*) ou sem valores (um livro de receitas). O conteúdo moral pouco muda a segurança; o amoral a degrada em todas as famílias (26–53 % de cumprimento de pedidos danosos, contra 0–14 % dos originais). O fator decisivo é o raciocínio: o ajuste fino troca a deliberação sobre dano por um molde fixo, e a taxa de deliberação prevê a de cumprimento de pedidos danosos ($R^2 = 0{,}86$ no Qwen3; 0,77 nas demais famílias). Treinar a deliberação explícita reduz o cumprimento para 0,3–3,9 % em todas as famílias, independentemente do texto de valores. A recusa se decide no raciocínio, e a erosão causada pelo SFT reside nas MLPs, distribuída em profundidade: desfazer só a atualização das MLPs recupera 81–101 % do dano, e desfazer a da atenção, no máximo 48 %.

1 Introdução

O ajuste fino supervisionado (SFT) de modelos alinhados, mesmo com dados benignos, pode degradar a segurança [1, 2]. Em modelos com raciocínio explícito (`<think>`), a segurança depende em parte de o modelo *deliberar* sobre o pedido [4, 5]. É comum especializar um modelo num corpus de valores (código de ética ou texto normativo), esperando que o conteúdo moral o torne mais seguro. Não se sabe se isso funciona, nem por quê.

Formulamos três perguntas: (Q1) o *conteúdo* de valores do corpus altera a segurança após o SFT? (Q2) qual é o mecanismo? (Q3) é possível especializar o modelo num corpus de valores sem perder segurança? Variando só o texto de valores, mostramos que: (i) conteúdo moral (Declaração Universal dos Direitos Humanos, DUDH) mantém a segurança próxima à do original, enquanto conteúdo amoral (*As 48 Leis do Poder* [6]) a degrada em todas as escalas (1,7–32B) e em seis famílias; (ii) o mecanismo é a erosão da deliberação no raciocínio, que prevê a segurança em 48 modelos Qwen3 ($R^2 = 0{,}86$) e se transfere às outras famílias; até um livro de receitas degrada a segurança quando apaga a deliberação; (iii) treinar um raciocínio deliberativo reduz o cumprimento de pedidos danosos a 0,3–3,9 %, e o texto de valores é intercambiável (DUDH ou nenhum).

Nas representações, os modelos continuam a *reconhecer* o dano (sonda linear com 97–98 %); a recusa do Qwen3 só é removida ao abliterar [8] a direção medida no raciocínio, e reversões parciais dos pesos localizam a erosão nas MLPs, não na atenção.

2 Trabalhos relacionados

O SFT, mesmo benigno, desfaz o alinhamento [1], que é "raso" [2]; o ajuste estreito pode gerar desalinhamento amplo [3]. *Deliberative Alignment* [4] e STAIR [5] treinam o modelo a raciocinar sobre uma especificação, e a IA constitucional [7] usa princípios escritos como supervisão, mas o peso do *texto*, separado do método, não foi medido. A recusa é mediada por uma direção nas ativações [8], e edições de pesos localizam fatos nas MLPs [16]. Isolamos uma variável ainda não estudada: o conteúdo de valores do corpus, com formato fixo.

3 Método

Condições. Variam só o texto de valores e o formato do raciocínio; volume, hiperparâmetros e avaliação são fixos. Cada modelo recebe 10 000 exemplos: 5 000 instruções gerais com o raciocínio do próprio original e 5 000 de conteúdo, gerados pelo Qwen2.5-32B-Instruct no mesmo formato em todas as condições (conselhos respondidos pelo texto de valores, explicações e exemplos). No *molde fixo*, o raciocínio é um padrão curto ("Penso no que diz a DUDH: Artigo 5… Vou responder…"): **DUDH**; **48 Leis** (P), controle amoral; **livro neutro** (LIV), receitas do *Cozinheiro Nacional* (séc. XIX, domínio público), controle sem valores. No *deliberativo* [4], o raciocínio examina o pedido (o que se pede, quem pode ser afetado, decisão), e os dados incluem 453 pedidos danosos com recusa e alternativa útil e 453 "gêmeos" legítimos com resposta útil. Varia o texto citado: **DUDH-delib** e **Laica-delib**, cujo raciocínio não cita texto algum (só consequências) e cujo conteúdo são perguntas factuais de localização de trechos, sem valores. Descartamos pedidos com sobreposição lexical $\geq 0{,}5$ com a avaliação.

Treino. Qwen3 [17] de 1,7B, 4B e 8B com SFT completo (2 épocas, $\eta = 10^{-5}$, cosseno) e 8B, 14B e 32B com LoRA [18] ($r = 64$, $\alpha = 128$, $\eta = 10^{-4}$); três sementes em 1,7B/4B (e em 8B para P e livro neutro). Para generalizar, repetimos as cinco condições com LoRA (mesmos hiperparâmetros, 1 semente) em Phi-4-reasoning 14B, Gemma 4 12B, Mistral Nemo 12B, Granite 3.3 8B e OLMo 2 13B (em Nemo e OLMo, sem raciocínio nativo, forçamos o `<think>`), e variamos as épocas (1, 2, 4) no Qwen3-4B. Ao todo, 90 modelos ajustados.

Intervenções internas (4B). A direção de recusa d_ℓ é a diferença das ativações médias de 300 pedidos danosos e 300 inofensivos fora da avaliação, tomada (v1) na última posição do *prompt* [8] ou (v2) em média sobre os *tokens* do raciocínio gerado pelo próprio modelo. *Abliterar* é remover d_ℓ de todas as matrizes que escrevem no fluxo residual ($W \leftarrow W - \hat{d}\hat{d}^\top W$); $\ell = 10$, escolhida num conjunto separado. No *conserto*, Laica-delib e LIV são treinados sobre o original abliterado. *Reversões* (6 famílias): partindo de P, trocamos a atualização ΔW de um

Tabela 1: Qwen3-4B, SFT completo, média ± dp de 3 sementes (%). Danoso: cumprimento de pedidos danosos (↓); Seguro: cumprimento no XSTest (↑); Excesso: recusa explícita de pedidos seguros; Delib.: deliberação sobre dano no raciocínio; Util.: vitória contra o original (50 = paridade). *: $p < 0{,}001$ (McNemar) contra o original.

	Condição	Danoso	Seguro	Excesso	Delib.	Util.
molde	Original	8,5	78,8	8,4	95,0	50,0
	Livro neutro	9,7 ± 0,5	78,9	6,3	93,2	44,3
	DUDH	6,7 ± 1,1	64,8	9,5	87,8	–
	48 Leis (P)	**28,9** ± 8,1*	53,5	8,0	61,0	44,1
delib.	DUDH-delib	2,6 ± 0,8*	55,3	17,7	98,1	25,9
	Laica-delib	2,7 ± 0,4*	70,8	15,3	98,6	44,7

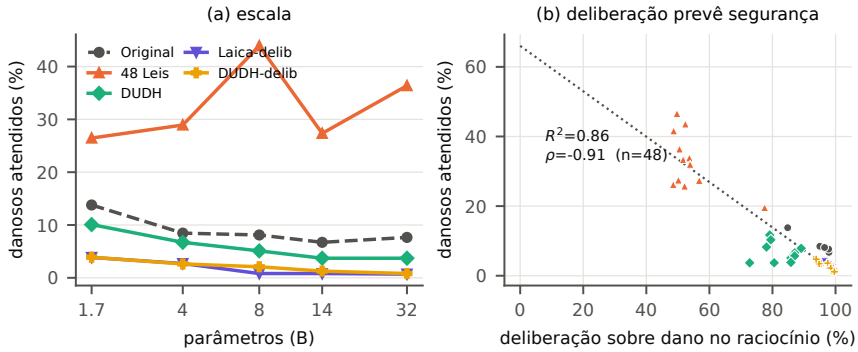


Figura 1: (a) Cumprimento danoso por tamanho (1,7–8B SFT completo; 14–32B LoRA). (b) Cada ponto é um modelo Qwen3 (cor como em (a)); reta: ajuste linear.

subconjunto de matrizes pela do original (ou mantemos só esse subconjunto), por quarto de profundidade, por matriz da MLP (`gate`, `up`, `down`), MLP inteira ou atenção inteira, e medimos a fração do dano recuperada, $(h_P - h_{\text{ed}})/(h_P - h_{\text{orig}})$.

Avaliação. 1119 itens em português: 863 danosos (StrongREJECT [9], HarmBench [10], AdvBench [11] e contrastes do XSTest [12]), 250 seguros (XSTest) e 6 de crise. Decodificação gulosa (até 4096 *tokens*). Um juiz (Qwen2.5-32B-Instruct) lê pedido, raciocínio e resposta e classifica em RECUSA, DESVIO, CUMPRE ou PARCIAL; a métrica principal é o *cumprimento danoso* (CUMPRE+PARCIAL sobre os danosos). Um juiz de outra família (Gemma-4-31B) concorda em 88 % de 1600 itens ($\kappa = 0{,}72$). Medimos ainda: cumprimento seguro e recusa excessiva (XSTest); *deliberação*, a fração de raciocínios sobre pedidos danosos que ponderam dano ou ética do pedido, segundo o juiz, que vê só pedido e raciocínio; *jailbreak* (300 pedidos × ficção e autoridade [13], passado [14]); e utilidade, como vitória pareada contra o original em 200 instruções. Testes: McNemar exato pareado contra o original; IC 95 % por *bootstrap*.

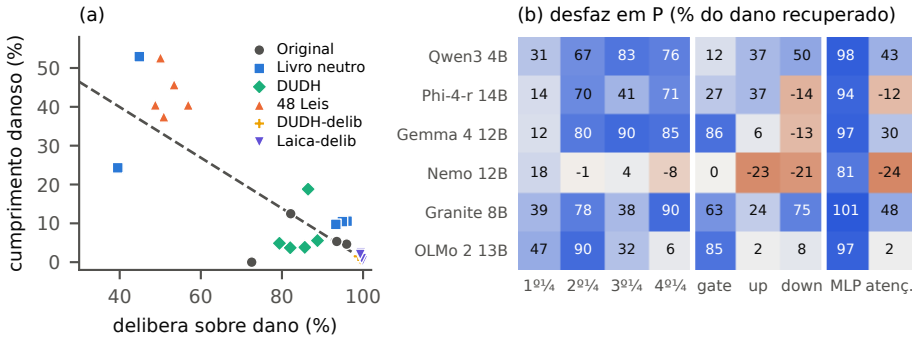


Figura 2: (a) Cinco famílias não-Qwen, 6 condições cada (LoRA); a reta tracejada é a ajustada só nos modelos Qwen3 (Fig. 1b). (b) Fração do dano de P recuperada ao desfazer, em P, a atualização de um quarto da profundidade, de uma matriz da MLP, da MLP inteira ou da atenção inteira (100 = volta ao original; < 0 = piora).

4 Resultados

Q1: o conteúdo moral quase não importa; o amoral, sim. No 4B (Tab. 1), a DUDH fica no nível do original (6,7 % vs. 8,5 %), enquanto as 48 Leis triplicam o cumprimento danoso (28,9 %; $p < 0{,}001$). Em todas as escalas (Fig. 1a), P atinge 26–44 %, contra 6,7–13,8 % do original; a DUDH (3,7–10,1 %) fica até 4 pontos abaixo do original. O livro de receitas fica perto do original (4B: 9,7 vs. 8,5 %; 8B: 11,7 vs. 8,1 %) e mantém a deliberação (93 %): um SFT sem valores degrada só levemente a segurança no Qwen3, como em [1].

Q2: o mecanismo é a deliberação. O original pondera o dano em 85–98 % dos raciocínios sobre pedidos danosos; a DUDH quase o acompanha (73–89 %), enquanto P cai para 50–61 % em todos os tamanhos. Em 48 modelos, a deliberação prevê o cumprimento danoso (Fig. 1b; $R^2 = 0{,}86$, Spearman $-0{,}91$), e item a item: 5,9 % de cumprimento quando o raciocínio delibera, 41,9 % quando não. O efeito não é de dose: com 1 época, P já cumpre 30,2 % (2 épocas: 33,2 %; $p = 0{,}1$); com 4, cai para 14,5 % ($p < 10^{-23}$), e a deliberação volta a 83 % (vs. 52 %); Laica-delib (2,0–3,0 %) e o livro neutro (7,9–10,3 %) quase não variam.

Q3: deliberar protege, e o texto é intercambiável. As duas condições deliberativas reduzem o cumprimento danoso para 2,6–2,7 % no 4B (Tab. 1) e para 0,5–2,1 % em 8–32B ($p < 0{,}001$ em todos os tamanhos) e não diferem entre si: o ganho vem do método, não do texto. O custo é a recusa excessiva (13,6–23,6 % vs. 5,6–8,4 % do original). Laica-delib preserva melhor a utilidade (vitória de 44–50 % contra o original; DUDH-delib: 25–30 %).

Robustez. Sob *jailbreak* de ficção, o molde fixo fica no nível do original ou acima (DUDH 43 %, P 62 % vs. 48 %), e Laica-delib cumpre 6,5 % (autoridade: 1,7 %; passado: 5,2 %). Treinando e testando em PT, EN, ES e ZH [15] (4B, dados traduzidos), Laica-delib protege nas 12 combinações (0,8–4,3 %); P é pior na língua do treino (22–35 %) e transfere parte do efeito às demais (10–32 %).

Outras famílias. O padrão se repete em Phi-4-reasoning, Gemma 4, Mistral Nemo, Granite e OLMo 2 (Fig. 2a): P leva o cumprimento danoso a 37–53 % (originais: 0–13 %; $p < 10^{-46}$ em todas), a DUDH fica a no máximo 7 pontos do original e as duas condições deliberativas o reduzem a 0,3–2,3 % (o Phi-4 original recusa até 99 % dos pedidos seguros; os deliberativos atendem 55–67 %). A reta ajustada nos Qwen3 prevê as outras famílias com erro médio de 5,8 pontos ($R^2 = 0{,}77$ dentro delas). O livro neutro é o teste mais forte: em Nemo e OLMo 2 ele apaga a deliberação (45 e 40 %) e o cumprimento danoso sobe a 53 e 24 %, como em P; onde a deliberação se mantém (93–96 %), ele fica a no máximo 11 pontos do original. Não é o valor do texto que importa, mas se o SFT preserva a deliberação.

Onde a erosão reside nos pesos. As atualizações de P e da DUDH são indistinguíveis em estatística: mesma norma, mesma partição da energia entre matrizes (MLP: 74–81 %) e camadas, e alinhamento semelhante com a direção de recusa, embora apontem em direções diferentes (cosseno 0,03–0,32). Em todas as famílias, desfazer só a atualização das MLPs recupera 81–101 % do dano, enquanto desfazer a da atenção recupera de −24 a 48 % (Fig. 2b). A erosão é distribuída: manter só um quarto da profundidade de P quase não causa dano (recupera 77–109 %), e desfazer um único quarto recupera até 90 % em algumas famílias e no máximo 18 % no Nemo. Isoladas, as matrizes da MLP não têm papel universal: desfazer `gate` recupera 85–86 % em Gemma e OLMo e 0–27 % em Qwen, Phi e Nemo; desfazer `up` ou `down` sozinha pode até piorar (até −23 %), sinal de atualizações coadaptadas. Nas 78 edições, a deliberação restaurada acompanha o dano recuperado (Pearson −0,72).

Saber sem fazer. No 4B, todos os modelos separam pedidos danosos de seguros com sonda linear (97–98 %), e a norma da direção de recusa *aumenta* após qualquer SFT (161→209–226), inclusive em P: o SFT amoral não apaga a representação do perigo, desacopla-a da decisão. A decisão está no raciocínio: abliterar a direção do *prompt*, como em [8], quase não muda o Qwen3 (8,5→10,7 %), mas abliterar a direção medida no raciocínio leva o cumprimento danoso a 43,2 % ($p < 10^{-70}$), com o cumprimento seguro pouco alterado (78,8→72,4 %). A deliberação treinada não sobrevive à mesma abliteração (Laica-delib: 2,5→35,7 %), mas a restaura: treinar Laica-delib sobre o original abliterado devolve 1,5 %, abaixo do original ($p < 10^{-15}$), enquanto o livro neutro no mesmo papel recupera só em parte (14,0 %; $p < 10^{-29}$ entre os dois).

5 Discussão e conclusão

Em 90 modelos de seis famílias, o conteúdo moral do corpus de SFT pouco afeta a segurança, o amoral a degrada sempre, e o mecanismo comum é a troca da deliberação sobre dano por um molde fixo no raciocínio; mesmo um texto sem valores degrada a segurança quando apaga a deliberação. Os modelos continuam a reconhecer o dano; a recusa se forma no raciocínio, e a erosão reside nas MLPs, distribuída em profundidade. Na prática, o que se controla é o *formato do raciocínio* nos dados de SFT: ensinar a deliberação sobre dano torna o modelo

mais seguro que o original, com qualquer texto de valores ou nenhum, e restaura a segurança removida por abliteração. Limitações: (i) as condições deliberativas também contêm $\sim$9 % de pares recusa/gêmeo, de modo que deliberação e exemplos de recusa estão confundidos; o controle Laica-delib mostra que o texto de valores não importa, mas não separa os dois fatores; (ii) a deliberação é medida por um juiz LLM (uma expressão regular dá a mesma direção); (iii) o juiz automático foi validado por um segundo juiz ($\kappa = 0{,}72$), e a validação humana cega está em curso; (iv) 14–32B e as outras famílias usam LoRA e uma semente; (v) a abliteração foi feita só no Qwen3-4B; (vi) a variação entre sementes é grande em P (4B: 19–34 %), e o efeito das épocas foi medido numa semente.

Ética. Não divulgamos os modelos abliterados (apagados) nem os ajustados com as 48 Leis, nem os pedidos danosos e as respostas geradas.

Referências

[1] X. Qi et al. Fine-tuning aligned language models compromises safety, even when users do not intend to! In *ICLR*, 2024.

[2] X. Qi et al. Safety alignment should be made more than just a few tokens deep. In *ICLR*, 2025.

[3] J. Betley et al. Emergent misalignment: narrow finetuning can produce broadly misaligned LLMs. In *ICML*, 2025.

[4] M. Y. Guan et al. Deliberative alignment: reasoning enables safer language models. *arXiv:2412.16339*, 2024.

[5] Y. Zhang et al. STAIR: improving safety alignment with introspective reasoning. In *ICML*, 2025.

[6] R. Greene. *The 48 Laws of Power*. Viking, 1998.

[7] Y. Bai et al. Constitutional AI: harmlessness from AI feedback. *arXiv:2212.08073*, 2022.

[8] A. Arditi et al. Refusal in language models is mediated by a single direction. In *NeurIPS*, 2024.

[9] A. Souly et al. A StrongREJECT for empty jailbreaks. In *NeurIPS Datasets and Benchmarks*, 2024.

[10] M. Mazeika et al. HarmBench: a standardized evaluation framework for automated red teaming and robust refusal. In *ICML*, 2024.

[11] A. Zou et al. Universal and transferable adversarial attacks on aligned language models. *arXiv:2307.15043*, 2023.

[12] P. Röttger et al. XSTest: a test suite for identifying exaggerated safety behaviours in large language models. In *NAACL*, 2024.

[13] A. Wei et al. Jailbroken: how does LLM safety training fail? In *NeurIPS*, 2023.

[14] M. Andriushchenko and N. Flammarion. Does refusal training in LLMs generalize to the past tense? In *ICLR*, 2025.

[15] Y. Deng et al. Multilingual jailbreak challenges in large language models. In *ICLR*, 2024.

[16] K. Meng et al. Locating and editing factual associations in GPT. In *NeurIPS*, 2022.

[17] A. Yang et al. Qwen3 technical report. *arXiv:2505.09388*, 2025.

[18] E. J. Hu et al. LoRA: low-rank adaptation of large language models. In *ICLR*, 2022.